第二十届D2技术大会

20TH D2 TECHNOLOGY CONFERENCE

AI·新

AI驱动创新

2026.03.24

阿里巴巴全球总部_访客中心

中国杭州 HANGZHOU CHIA

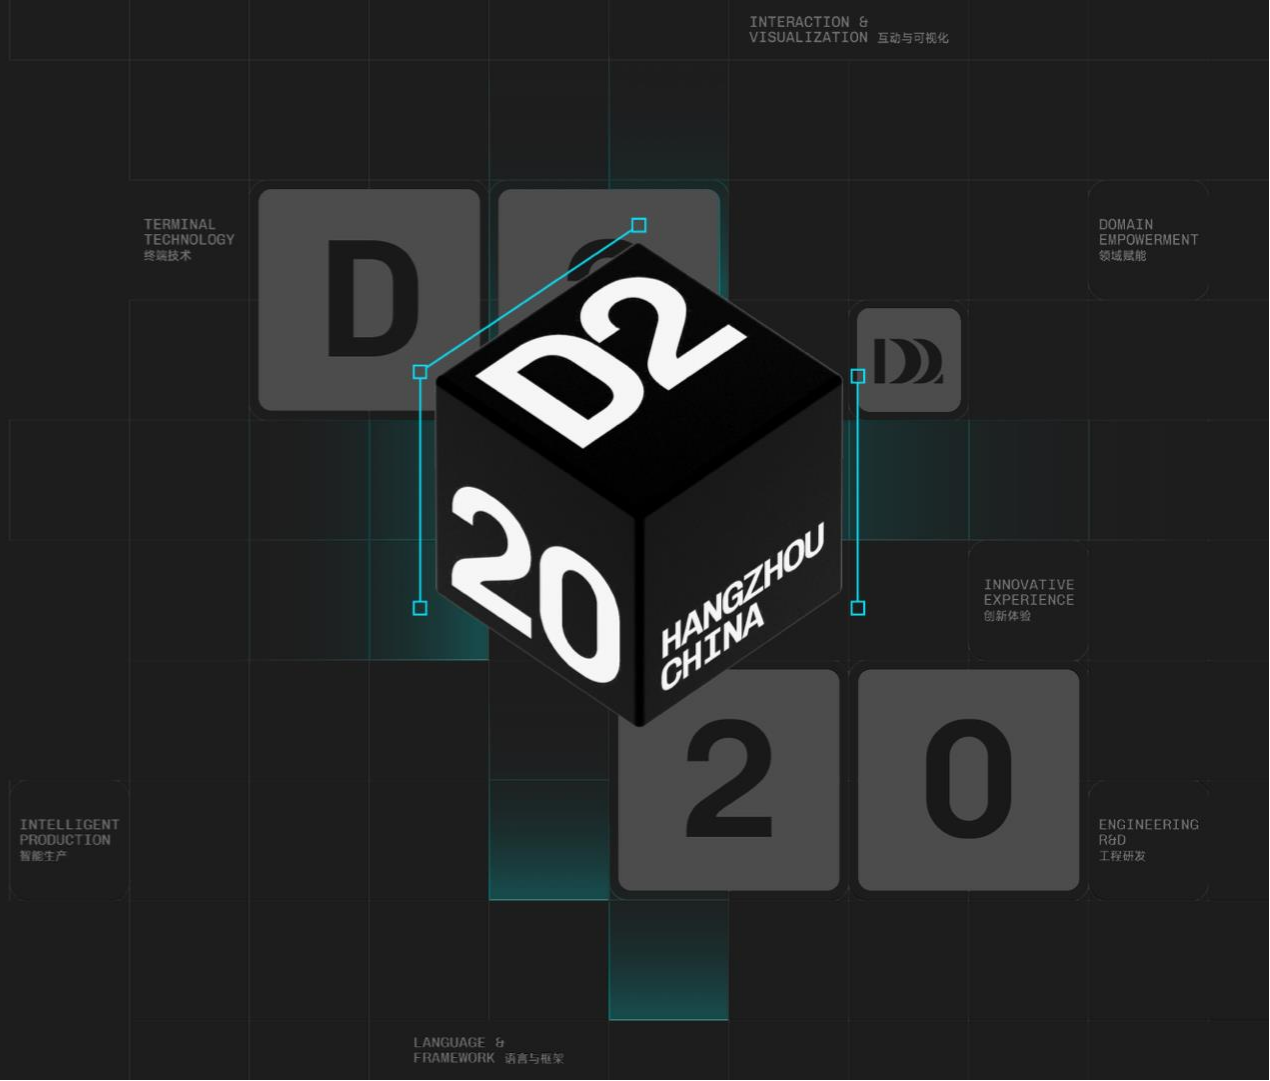

从上下文工程到
Harness Engineering

构建高效的 Agent 执行环境：上下文工程 & 工具链设计

分享人：周晓 | Web Infra AI coding 负责人

About me

- 周晓 / zhoushaw
- 字节 Web Infra 成员
- AI Coding / Harness Engineering
- Midscene.js / Module Federation 2.0

AI 时代的研发焦虑与反思

是什么让我们在代码生成的狂欢中感到不安?

为什么 AI 出现后，研发普遍觉得更累了？

真正的瓶颈：编码提速并未打破系统性天花板，非编码工作量正在随着代码生成量的增加而指数级爆发。

软件开发工作时间分配

⚠ 非编码工作占比高达 70%

局部最优陷阱

AI **目前只在开**发环境里极速写代码，但并没有帮你解决测试、验证和沟通等环节。价值上限被后续流程死死锁住。

痛点爆发：代码生成得越快越多，你用于手动测试、验证排障和 Code Review **的工作量正在呈指数级上升**。

破局：Harness Engineering

必须从"单行代码补全"跃升至让 Agent 执行跨越整个生命周期的**长时间闭环任务 (Long-term Tasks)**。

核心路径：通过专属工具链集成，解决上下文爆炸问题，让 AI **接管**测试与排障，彻底打破 70% **的非**编码流程枷锁。

范式转移：什么是 Harness Engineering？

工程师角色转变

从“编写代码”转向“设计环境、明确意图”

Harness Engineering

构建 Agent 专属工具链，实现受控执行

Agent 可读性

北极星指标：代码库重塑为模型能“读懂”的环境

“不要只把大模型看作‘大脑’，必须为它打造专属的‘工作室’。”

PART 01

唯快不破 — 从 Transformer 原理到 Prompt Cache

Transformer 自回归、KV Cache、Prompt Cache、ReAct 循环、上下文布局

Claude Code / Codex 在遵循哪些“物理限制”？

你觉得产品“慢、笨、会幻觉”？其实每个行为都是一道工程选择题

SLOW / 慢

并非产品 Bug

自回归逐 Token 生成是物理铁律；上下文越长，Prefill 就越久，这是算力的基本开销。

DUMB / 笨

并非模型能力弱

上下文塞得越多，注意力被稀释得越严重。在万行代码中，关键逻辑往往被掩埋。

HALLUCINATION / 幻觉

并非故意欺骗

当上下文中缺少事实锚点，模型为维持概率连贯，只能进行“合理的猜测”。

*产品设计并非在对抗限制，而是在做**Harness Engineering**：顺应物理限制，在约束中求解最优体验。*

1.2–1.3 KV Cache & Prompt Cache

解释了为什么 System Prompt 要保持极高稳定性 —— 只有稳定，缓存才能命中，响应才能加速

1.4 ReAct 循环机制

解释了为什么 Agent 要"想→做→看"反复迭代 —— 利用外部反馈来对冲模型的概率波动

上下文布局与压缩

解释了为什么会自动 Compact —— 在有限的注意力槽位内，塞入信噪比最高的信息

理解这些约束 = 理解 Harness Engineering 的底层逻辑

NEXT: 以 Transformer 第一个 Token 为起点，逐层拆解 →

1.1 为什么是一个 token 一个 token 吐？

自回归分解

LLM 本质是"下一个 token 预测器"

$$P(x_1,\ldots,x_T) = \prod P(x_t \mid x_1,\ldots,x_{t-1})$$

- 流式渲染暴露了模型自回归的物理现实
- 无 KV Cache 时，吐第 100 词 → 前 99 词全部重算
- Coding Agent 塞入几万字 → Prefill 阶段极其昂贵

PyTorch 朴素推理（无 KV Cache）

```
for step in range(max_tokens):
    # 朴素实现：每步全量前向
    out = model(input_ids)
    next = argmax(out.logits)
    # 拼接 → 序列越来越长
    input_ids = cat([input_ids, next])
```

结论：上下文越长 → Prefill 越重 → 首 Token 延迟越大 — 这就是 KV Cache 的动机

1.2 KV Cache：为什么"追加"便宜？

推理两阶段：Prefill（全量算 KV）➤ Decode（复用 KV）

Attention 的物理本质：

Q：问题 | K：标签 | V：细节

标准 Attention 公式

$$\mathrm{Attention}(Q,K,V) = \mathrm{softmax}(QK^T/\sqrt{d})\,V$$

长任务黄金定律：

✅ **追加 (Append) 极度便宜**

老 KV 复用，新 token 只算一次

❌ **中间修改 极其昂贵**

修改点之后的所有 Cache 全部作废重算

⚡ **核心结论：**一切上下文工程，本质上都是为了"尽量不破坏前缀"

追加 = 复用 KV，O(新 token) | 修改 = 从修改点起重算 KV，O(N)

1.3 Prompt Cache：多快省

缓存KV → 跳过Prefill → 更快+更省

Claude Sonnet 4.6定价实例

Base Input **$3.00** / MTok	**$3.00** / MTok
Cache Write (5min) **$3.75** / MTok (1.25x)	**1.25x**
Cache Read **$0.30** / MTok (0.1x)	**↓90%!**

更快

Req → Cache → → TIFT: 大幅缩理

更省

Cache Read 仅 0.1x 基础价格。
更多上下文 → 更多节省。

工作原理

Input + → Write KV, 1.25x (5min)

Input + → Read (0.1x)，节省90%

1.4 ReAct：Agent 的操作系统

不是"一问一答"，而是 Thought → Action → Observation 的循环

一个真实的 ReAct 过程

User: 给 user-service 加 /healthz 接口

Reason: 先找路由注册方式……

Act: `search / read_file`

Observe: 返回文件内容

Reason: 原来是 FastAPI，该这样写……

Act: `write_file + bash pytest`

Thought (思考)

"需要查看 index.ts 的错误信息"
模型在上下文里"自言自语"

Action (行动)

`read_file() / write_file() / bash()`
调用工具，影响物理世界

Observation (观察)

返回文件内容、终端输出、报错信息
结果追加到上下文 → 触发下一轮

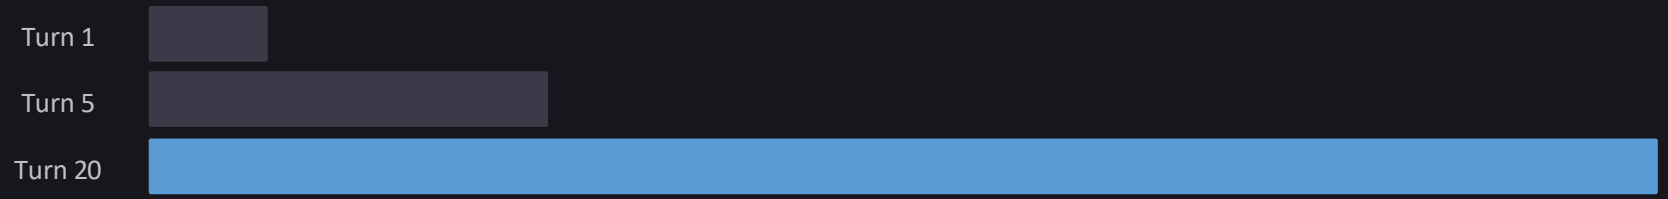

上下文随迭代爆炸 → 第一原则：保护前缀稳定性 → 接下来：怎么做？

思考一下

你的 Agent 工具，平均每轮往上下文里塞多少 token？

如果超过 5,000 token，你的 Cache 命中率可能已经崩了

接下来：从原理走向实战 — 上下文工程的具体策略

PART 02

上下文工程实战

Prompt 布局、缓存优化与上下文膨胀的应对策略

一次 Agent 任务背后：Prompt 的五层结构

不是"把你的话丢给模型"，而是构造了一整坨 Prompt

1 System	模型服务商系统提示 + Agent 身份定义 + 工具能力声明
2 AGENTS.md	技术栈、代码风格、安全边界、团队工作流
3 项目快照	当前工作目录、选中文本、项目结构
4 会话历史	对话记录 + 工具调用与返回 + snapshot / 总结
5 工具定义	MCP 工具清单：名称 + 说明 + JSON Schema

⚡ **核心结论：上下文不是"越多越好"，而是要"把最重要的东西放到最该放的位置"**

所有这些一起拼成 Prompt → 位置和占比决定了模型的注意力分配

记忆的艺术： Compaction + AGENTS.md

上下文不是越多越好 — 要主动压缩、主动归档、主动锚定

主动 Compaction 流程

- 关键节点总结状态
- 浓缩为结构化 snapshot 文件
- 清理对话，读取 snapshot

→

好处：

- ✅ 版本管理 & 可 review
- ✅ 对话不堆积
- ✅ 统一"状态锚点"

AGENTS.md — 项目宪法

- 自动放置 Prompt 最前面
- 不会被压缩/总结
- 所有 Agent 默认遵守

✅ 建议写入内容

技术栈/框架

代码风格约定

安全边界

❌ 不要写入内容

一次性需求

经常变动的信息

临时重构目标

⚡ 核心策略实现

前缀稳定 → KV Cache 好复用 ⚡ Sub Agent / snapshot/Spec替换长历史 → AGENTS.md 钉死宪法

抵抗膨胀：将上下文外包给"知识记录系统"

不在代码仓库里的隐形知识，对 Agent 来说就是不存在的

🔄 ReAct 长对话

膨胀的中间过程

试错日志、调试输出、

工具调用结果...

→

📝 主动 Compaction

将当前分析结果

浓缩成结构化快照

清空对话历史

→

📁 结构化文件

`docs/state/migration.md`

下次 read_file 即可恢复

⚠️ 隐形知识的陷阱

业务决策如果只在聊天记录里，对 Agent 就是不存在的。

正确姿势：执行完一个阶段 → 将探讨结论写成 Markdown 快照 → 清空对话历史 → 下次 read_file 恢复

⚡ **核心结论：**记忆外包给文件系统 — 但上下文治理只是一半，工具设计同样关键 →

PART 01-02 CHECKPOINT

到这里，你需要带走的 3 条核心结论

1 自回归 → 上下文越长，重复计算越多
每生成一个 token 都要重算所有历史 — 这是模型的物理现实，无法绕过

2 KV Cache → 追加便宜，修改昂贵
保护前缀稳定性 = 复用缓存 = 省钱 + 提速，中间插入 = 缓存作废

3 上下文是最贵的资源 — 治理它，而不是堆砌它
三段式布局 + 主动 Compaction + 记忆外包给文件系统

⚡ **一句话：**所有后续策略的根基 — 保护前缀稳定性

PART 03

工具设计与 Agent 可读性

Agent 可读性、好工具标准、MCP / Skill / Sub Agent、闭环校验

核心范式转移：提升 Agent 可读性

从"对人友好"转向"对 Agent 可读" — 环境降维成结构化语义

过去的 Infra 陷阱		范式转移：一切为了 Agent 可读
酷炫 GUI / 海量终端日志 直接把给人类看的界面、十几页火焰图扔给 Agent → Token 瞬间爆炸，上下文被垃圾填满	→	**结构化语义 (JSON / API)** 精确、唯一的术语定义 Agent 直接解析，零歧义
面向鼠标点击的交互 Agent 无法操作 GUI 按钮和拖拽界面 → 人机交互范式完全不适用	→	**面向自然语言指令** 用文字描述操作意图，取代鼠标点击 Agent 原生理解，自主执行
视觉冗余图表 图形化仪表盘对 Agent 完全不可读 → 缺乏语义，无法提取结构化信息	→	**高信噪比的诊断摘要** 极致精简，层级分明的上下文导航 秒级反馈 + 100% 稳定结构化输出

Harness Engineering 的核心：给模型好的上下文、好的工具、可读的环境 — 这就是“为 Agent 打造专属工作室”的全部

好工具的标准

Agent 的工具质量直接决定 Harness 工程的成败

贴近物理上限

秒级冷启动与响应，防止 Agent 注意力涣散。

结构化输出

禁止 PDF/网页截图。必须输出 JSON/Markdown。

痛觉反馈

错误信息是闭环的起点，需精确到行号与类型。

⚡ **核心原则：**工具不是给人用的 UI — 是给 Agent 用的 API。快、准、结构化，缺一不可。

大脑分工：MCP、Skill 与 Sub Agent

当任务足够复杂，光靠原子工具是不够的 — 我们需要给大脑分工

MCP
原子动作 · 常驻上下文

一次性挂在上下文里，提供基础的"原子动作"
GitHub · Slack · Database · K8s · Internal APIs

Skill
可见的 SOP · 按需激活

把成熟打法（CI Debug、审查清单）固化成可执行文件夹，在主会话里按步骤跑
`skill.md + run.sh + examples/`

Sub Agent
黑盒外包 · 并行大脑

完全独立的会话，上下文隔离 — 适合超长任务拆解
例：Explore 模式 — 起 3 个并行子 Agent 探索不同微服务，最后汇总 Summary

⚡ **核心思路：** 用架构隔离，对抗长任务的熵增 — 原子动作 → 固化打法 → 并行外包

闭环校验与编辑：机器人的 LSP

自动化的 "Lint → Fix → Verify" 闭环

1. 静态分析
AST 检测
提前发现冲突

2. 增量重构
Agent 自动应用
最小差异

3. 动态验证
运行测试用例
真实反馈

⚠️ 为什么需要闭环？

Agent 每一次编辑都可能引入新错误。没有 Lint → Fix → Test 的自动闭环，Agent 就会在错误上堆叠错误，直到上下文爆炸。

⚡ **核心结论：** LSP 不是可选项 — 它是 Agent 编码质量的最低保障线。

PART 04

多智能体协作与受控执行

Agents Team、人机协作、Spec/Plan — 从单兵到团队作战

Spec Kit 与 Plan 模式：谋定而后动

先写规格，再写代码 — 减少无目的的试错循环

📋 Spec Kit (规格说明书)

定义"做成什么样"：

- 输入/输出 Schema
- 副作用边界 (Side Effects)
- 验证通过标准 (Success Criteria)

🗺️ Plan 模式 (执行计划)

定义"怎么做"：

- 多步任务拆解
- 关键检查点 (Checkpoints)
- 失败回退策略 (Rollback)

⚡ **核心结论：** Spec 答 What，Plan 答 How — 不确定时在第 1 轮就向人求助，而非猜错后浪费 20 轮

人机协作：Agent 何时该自主，何时该求助

Harness 不是让 Agent 完全取代人 — 而是让人机各司其职

🎯 受控闭环

🤖 Agent 自主执行

- Spec 明确 + 有闭环验证
- 工具能力覆盖完整
- 失败可自动回退

→ 放手让 Agent 跑

🧑 向人求助 (AskUser)

- 意图模糊 / 多条路径
- 环境信息不足
- 涉及不可逆操作

→ 第 1 轮就问，不猜

⚡ **Harness 的边界：** 好的工具链让 Agent 知道自己能做什么、不能做什么 — 这本身就是 Harness

突破智能上限：Agents Team 与结构化通信

单 Agent 天花板 = 模型基础智商 → 用多智能体协作来突破

单 Agent

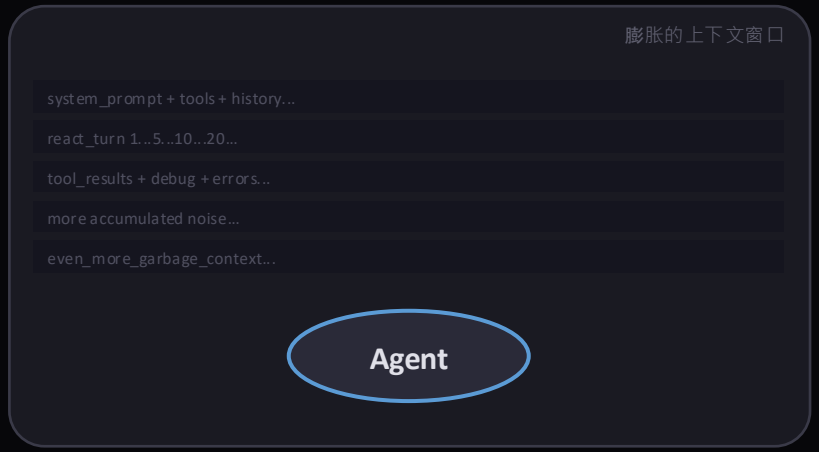

上下文膨胀 → 注意力稀释

智商被锁死在模型基础水平

Agents Team

仅通过结构化摘要通信

物理隔离噪音 · 独立上下文

交叉验证 · 突破智能上限

核心理念：用"结构化通信"代替"无脑堆砌"— Agent 在独立沙盒工作，只交换摘要

回想一下

上次让 Agent 跑一个超过 20 轮的任务，
它在第几轮开始"变笨"？

接下来看看我们的工程化解法 — 如何让 Agent 稳定跑完全程

PART 05

释放人类注意力 & 构建 AI native 工具

AI 降维 · 全链路流水线 标准化基建

基于 Agent 的 CLI 自迭代端到端闭环

Step 1：需求输入 (Input)

自然语言描述交互修改需求

Step 2：AI 自动编码 (Code)

Agent理解需求，自动定位并修改代码逻辑（UI 层与 Middleware 层）

Step 3：自动化沙盒测试 (Test)

核心动作：AI 调用内置 `cli-test` skill

技术细节：基于 `tmux` + **Aiden CLI 操作手册**，进行行实的终端 UI 交互自测

自我验证通过，确保功能满足需求

Step 4：交付验收报告 (Output)

AI 自动沉淀飞书交付文档

- 变更范围说明
- TUI 截屏前后对比
- 自动化测试执行方案

从 Review 代码到 Review 交互和测试

SKILL.md	.aiden/skills/cli-test/SKILL.md	+1 -1	Viewed
interaction-guide.md	.aiden/skills/cli-test/interaction-guide.md	+37 -19	Viewed
feat-slash-skill-merge.md	.changeset/feat-slash-skill-merge.md	+5 -0	Viewed
plugin_command.test.ts	next/cli/e2e/plugin/plugin_command.test.ts	+1 -1	Viewed
skill_dollar.test.ts	next/cli/e2e/skill/skill_dollar.test.ts	+0 -460	Viewed
custom_slash.test.ts	next/cli/e2e/slash/custom_slash.test.ts	+5 -5	Viewed
normal_slash.test.ts	next/cli/e2e/slash/normal_slash.test.ts	+3 -2	Viewed
index.ts	next/cli/src/ui/commands/index.ts	+2 -0	Viewed
skills.tsx	next/cli/src/ui/commands/skills.tsx	+11 -0	Viewed
SkillsPanel.tsx	next/cli/src/ui/components/SkillsPanel.tsx	+119 -0	Viewed
SkillSelectionDropdown.tsx	next/cli/src/ui/components/SmartInput/SkillSelectionDropdown.tsx	+0 -109	Viewed
SlashCommandDropdown.tsx	next/cli/src/ui/components/SmartInput/SlashCommandDropdown.tsx	+84 -42	Viewed
index.tsx	next/cli/src/ui/components/SmartInput/index.tsx	+6 -15	Viewed

MR: 合并 Skill 与 Command 到统一的 / 下拉菜单

修改范围

- 核心代码变更（next/cli/src）
- E2E 测试变更（next/cli/e2e）
- 文档变更

E2E 测试策略

截屏对比

- 改前：独立的 $ 触发 skill 下拉
- 改后：统一的 / 下拉（builtin + command + skill 混排）
- 改后：过滤搜索 skill
- 改后：选中 skill → 输入框显示 /skillName
- 改后：/skills 内置命令
- 改后：$ 不再触发任何下拉

Skill 完整执行流程

- Step 1: 输入 /echo，下拉列表显示 echo-test skill
- Step 2: 按 Enter 选中，输入框显示 /echo-test（斜杠前缀，下拉消失）
- Step 3: 追加参数 hello world，输入框显示 /echo-test hello world
- Step 4: 按 Enter 提交，/ 自动转换为 $，SDK 正常执行 skill

端到端闭环交付， Aiden CLI

需求：将 CLI 的 skill 列表和 command 列表合并为统一的 / 触发下拉菜单（对齐 Claude Code 交互）。

改前：独立的 `$` 触发 skill 下拉

代码块

```
> $

 $ Select Skill (search...)
 ❯ analyze
   cli-test
   e2e-test-debugger
   tmates-docs-generator
   gitlab:gitlab-action

 ↑↓ Navigate • Enter Select • Esc Cancel
```

`/` 下拉只有 builtin 和 markdown command，skill 需要用 `$` 单独触发。

改后：统一的 `/` 下拉（builtin + command + skill 混排）

代码块

```
> /

Type to filter • Tab to complete
/agents
     Manage subagents - create, view, delete  [builtin]
/analyze
     Analyze a LangSmith trace by id...  [command:project]
/analyze
     Fetch LangSmith traces and threads...  [skill]
/clear
     Clear agent context, session history, and screen content  [builtin]
/cli-release-note
     获取版本发布日志并更新 CHANGELOG.md  [command:project]
/cli-test
     Test the CLI by launching it in tmux...  [skill]
/compact
     Manually trigger context compression to save tokens  [builtin]

Showing 1-7 of 27 commands

↑↓ Navigate • Enter Confirm • Esc Cancel
```

周晓 2584

Midscene.js: 为 Agent 打造 AI Native 的工具

当 Agent 需要操控网页时，有两条路径

Agent 自己控制网页

获取网页 DOM 树

`document.querySelector(...)`

解析结构 / 截图识别

视觉模型 + 坐标映射

定位目标元素

CSS 选择器 / XPath

模拟人类操作

`click(x,y) / type(text)`

Agent 在做人类才需要做的事

上下文爆炸 · 脆弱 · 无法自愈

Agent + Midscene.js

Agent 用自然语言描述意图

"点击登录按钮" "验证购物车有3件商品"

↓

Midscene 原生理解并执行

自主定位 · 自动适配 · 自愈重试

AI Native = 为模型设计的工具

不获取 DOM · 不截图 · 不模拟人类操作

自然语言本身就是 Agent 的操控接口

好的 Harness = 为 Agent 量身打造 Native 工具

从“模拟人类”到“AI Native”：重塑 Agent 开发全链路闭环

核心价值总结：释放人力注意力，构建高效工具

1. 破局：将人从“AI 调试器”中解放

(UNBURDEN HUMAN ATTENTION)

痛点：人机纠缠

传统 Agent 需要人类密切关注过程，观察 TUI/UI 截图，进行 DOM 定位纠错，注意力被繁琐细节锚定。

解法：自我验证闭环

引入基于 `tmux` 的自动化沙盒环境与内置 `cli-test` 技能，Agent 在内部自动完成测试。

价值：结果导向交付

人类仅需审计最终生成的 飞书验收报告 （含对比截图和测试报告），无需人工监控。

2. 进化：构建 AI Native 的生产力工具

(BUILD AI-NATIVE HARNESS)

理念转变

不再强迫 AI 模拟人类脆弱的操作（获取 DOM、计算坐标、模拟点击）。

Midscene.js 核心能力

- **自然语言接口**：将复杂 Web 操作抽象为“点击登录按钮”等简洁指令。
- **原生理接与执行**：工具层实现自主定位、自动适配与自愈重试，模型与环境无缝握手。

效率跃迁

消除上下文爆炸，提升任务鲁棒性和成功率。

总结与展望：AI 时代的研发新范式

CONCLUSION & OUTLOOK: THE NEW R&D PARADIGM IN THE AI ERA

1. 从编码者到 BUILDER
(FROM CODER TO BUILDER)

- 核心角色转变
- **Harness Engineering:** 为 AI 提供工具、上下文、反馈。

2. 驾驭模型物理限制
(MASTERING MODEL CONSTRAINTS)

- 利用 Transformer 自回归特性和 Prompt Cache 问题。

3. 连接物理世界
(CONNECTING TO THE REAL WORLD)

- 模型落地需要精准工具与上下文。

4. 时间是稀缺资源
(TIME IS SCARCE)

- 人类时间是最稀缺的资源。
- 让 AI 处理繁琐任务，释放人类创造力。

Q & A

欢迎提问与交流环节

(Open for Questions & Discussion)